

UNIDAD N° 1

ESTADÍSTICA DESCRIPTIVA

ORGANIZACIÓN DE LOS DATOS – MÉTODOS GRÁFICOS

En estadística, los datos no solo se analizan con fórmulas y cálculos: también se leen a través de representaciones visuales. La forma en que se presentan los datos influye directamente en la claridad con la que se interpretan. Una buena visualización permite detectar patrones, identificar errores, comparar grupos o anticipar comportamientos, todo de un vistazo.

Como futuros programadores y programadoras, poder ver los datos de forma adecuada es el primer paso para comprenderlos y tomar decisiones fundamentadas. Ya sea que estén desarrollando un software de control de calidad, una herramienta de análisis de rendimiento o una app de visualización interactiva, los métodos gráficos serán aliados clave en su trabajo profesional.

En esta sección exploraremos distintas maneras de representar conjuntos de datos utilizando gráficos adecuados al tipo de variable, cantidad de datos y objetivo del análisis. No se trata solo de “dibujar”, sino de representar datos de forma estratégica para facilitar el análisis y la comunicación.

DIAGRAMA DE PUNTOS

El diagrama de puntos es una herramienta sencilla y eficaz para representar datos numéricos cuando el conjunto de observaciones no es muy extenso. Se utiliza principalmente con variables cuantitativas discretas o continuas que presentan pocos valores distintos. Cada valor se ubica sobre una línea horizontal, y por cada vez que ese valor aparece en el conjunto de datos se representa un punto. Si un valor se repite, los puntos se apilan en una columna vertical.

Este tipo de representación permite observar rápidamente si los datos presentan concentración en determinadas regiones, si existen valores atípicos o si hay intervalos del eje donde no se registraron datos. Es particularmente útil en etapas preliminares del análisis, cuando se busca explorar la forma general de la distribución de los datos.


A modo de ejemplo, consideremos un conjunto de datos que representa los tiempos de ejecución (en segundos) de un script automatizado utilizado para realizar respaldos diarios en distintos servidores de una empresa de software. El diagrama de puntos permite visualizar rápidamente qué tan consistentes fueron esos tiempos, si hubo ejecuciones atípicamente lentas o rápidas, y en qué valores se concentraron la mayoría

de los registros.

Ejemplo: Tiempos de ejecución (en segundos) de un script automatizado utilizado para realizar respaldos diarios en distintos servidores de una empresa de software. Construir el diagrama de puntos.

2,2	4,1	3,5	4,5	3,2	3,7	3,0	2,6
3,4	1,6	3,1	3,3	3,8	3,1	4,7	3,7
2,5	4,3	3,4	3,6	2,9	3,3	3,9	3,1
3,3	3,1	3,7	4,4	3,2	4,1	1,9	3,4
4,7	3,8	3,2	2,6	3,9	3,0	4,2	3,5

Solución:



Lectura e interpretación del gráfico.

Al observar el diagrama de puntos, se aprecia una clara concentración de tiempos de ejecución en torno a los valores de 3,0 a 3,6 segundos, lo que sugiere que ese es el comportamiento más frecuente del script. Este patrón indica una buena estabilidad en los tiempos de procesamiento, aunque se detectan algunas ejecuciones más rápidas (alrededor de 1,6 segundos) y otras más lentas (cercanas a 4,6 segundos), que podrían corresponder a condiciones particulares del sistema o del entorno de red. El gráfico también muestra que no hay grandes saltos ni zonas sin datos en el rango intermedio, lo que refuerza la idea de un rendimiento relativamente constante. Esta visualización resulta útil y constituye una primera aproximación visual antes de aplicar técnicas más avanzadas de análisis, como por ejemplo de detección de valores atípicos.

DIAGRAMA DE TALLO Y HOJAS

Al igual que el diagrama de puntos, el diagrama de tallo y hojas permite representar los datos numéricos mostrando cada valor individual del conjunto de datos. La diferencia

es que, en lugar de ubicar los puntos sobre una escala, los datos se descomponen en dos partes, el tallo y la hoja, lo que facilita observar la forma general de la distribución manteniendo, a su vez, la información exacta de cada dato.

Este tipo de representación es especialmente útil para conjuntos de datos pequeños o moderados. Muestra con claridad la concentración de valores, la simetría o asimetría de la distribución, y permite identificar rápidamente valores extremos.

Este gráfico consiste en separar cada número en dos componentes: el tallo (uno o más dígitos más significativos) y la hoja (el dígito o parte menos significativa). La elección depende del rango y la precisión de los datos. Por ejemplo, si los valores están entre 3,0 y 4,9, podría usarse la parte entera como tallo y la décima como hoja; pero si los datos fueran mayores, como 112 o 123, el tallo podría tener dos dígitos.

Los tallos se organizan en una columna vertical, y las hojas se alinean horizontalmente a su derecha.

Pasos para construir un diagrama de tallo y hojas:

1. Elegir qué parte del número se usará como tallo y cuál como hoja.
2. Ordenar los tallos de menor a mayor en una columna vertical.
3. Ubicar cada hoja al lado del tallo que le corresponda.
4. Aclarar las unidades de medida (por ejemplo: “las hojas representan decenas”).

Cuando los datos se concentran en un intervalo estrecho, puede resultar útil dividir cada tallo en dos partes, una para las hojas de 0 a 4 (tallo “bajo”) y otra para las hojas de 5 a 9 (tallo “alto”). Esto permite observar la distribución con mayor detalle.

Ejemplo: Construir el diagrama de tallo y hojas correspondiente a los datos del ejemplo anterior.

Solución:

Tallo	Hojas	Frecuencia
1	69	2
2	25669	5
3	0011112223334445567778899	25
4	11234577	8

Tallo	Hojas	Frecuencia
1A	69	2
2B	2	1
2A	5669	4
3B	001111222333444	15
3A	5567778899	10
4B	11234	5
4A	577	3

¿Qué información nos brinda este diagrama?

El diagrama revela que la mayoría de los tiempos de ejecución se concentran en el rango de los 3 segundos, con una leve inclinación hacia valores algo mayores. Esto indica una ejecución relativamente estable, con algunas variaciones mínimas. También se observan unos pocos valores más bajos (alrededor de 1,6 segundos) y algunos más altos (cerca de 4,6 segundos), que podrían indicar casos particulares de carga del sistema o configuración del entorno de prueba. En conjunto, la distribución muestra una tendencia central clara y un comportamiento predecible del script.

DIAGRAMA DE BARRAS

El gráfico de barras es una de las representaciones más utilizadas para visualizar frecuencias asociadas a distintas categorías. Resulta especialmente útil para mostrar la distribución de una variable cualitativa (nominal u ordinal) o una variable cuantitativa discreta con pocos valores distintos. Su principal ventaja es la claridad con la que permite comparar las frecuencias entre categorías.

En el eje horizontal se disponen las categorías o valores que puede tomar la variable, mientras que en el eje vertical se representan las frecuencias (absolutas o relativas). Cada categoría se representa con una barra cuya altura es proporcional a su frecuencia.

A diferencia del histograma, las barras en este gráfico no deben tocarse, ya que cada una representa una categoría independiente. En el caso de variables cualitativas nominales, el orden de las barras es arbitrario; en cambio, si se trata de una variable ordinal, conviene respetar el orden natural de las categorías para facilitar la interpretación.

Ejemplo: Un docente de la Tecnicatura en Programación realiza una encuesta a sus estudiantes para conocer sus preferencias al personalizar el entorno de desarrollo que utilizan en las prácticas. Se les consulta, entre otras cosas, cuál es su color favorito para aplicar como tema de interfaz en el editor de código. Las opciones eran: negro, azul, amarillo y rojo. Con los resultados obtenidos, se construye la tabla de frecuencias y un gráfico de barras que resume visualmente las preferencias del grupo:

Color	f_i	f_r
Negro	4	0,20
Azul	5	0,25
Amarillo	5	0,25
Rojo	6	0,30

En el eje horizontal (x), colocamos los valores de la variable, es decir, los colores preferidos: negro, azul, amarillo y rojo. En el eje vertical (y), colocaremos la frecuencia.

Gráfico utilizando la frecuencia absoluta





Gráfico utilizando la frecuencia relativa



Observemos que ambos gráficos presentan la misma “forma”.

¿Qué información nos brinda este gráfico?

El gráfico muestra que el rojo es el más elegido entre los estudiantes, seguido por el

azul y el amarillo, mientras que el negro tiene la menor cantidad de preferencias. Esta representación permite visualizar de forma clara las elecciones del grupo y puede ser útil al momento de tomar decisiones, como en este ejemplo sobre las preferencias de los alumnos.

Otro gráfico posible para representar proporciones categóricas es el gráfico circular, que estudiaremos a continuación.

GRÁFICO CIRCULAR

El gráfico circular, también conocido como gráfico de torta o de pastel, permite representar cómo se distribuye un total entre diferentes categorías. Es una herramienta útil para visualizar proporciones relativas y comparar cuán grande es cada parte respecto al todo.

Cada categoría se representa como un sector del círculo, y su tamaño es proporcional a la frecuencia relativa o porcentaje que representa. Por ejemplo, si un sector ocupa el 25 % del círculo, significa que esa categoría representa un cuarto del total de los datos.

Este tipo de gráfico se utiliza con variables cualitativas o cuantitativas discretas agrupadas por categoría, y es especialmente efectivo cuando hay pocas categorías y sus diferencias son notorias. Cuando hay demasiadas categorías o los porcentajes son similares, su lectura puede volverse confusa.

Ejemplo:

Durante una encuesta entre estudiantes de primer año de la Tecnicatura, se consultó cuál era su sistema operativo preferido. Las respuestas se agruparon en cuatro categorías:

Sistema Operativo	f_i	f_r	Porcentaje
Windows	18	0,45	45
Linux	12	0,30	30
macOS	6	0,15	15
Otros	4	0,10	10

A partir de estos datos, se construye el siguiente gráfico circular:



¿Qué podemos interpretar del gráfico?

El gráfico circular muestra con claridad que Windows es el sistema más elegido, representando casi la mitad de las preferencias. Linux ocupa el segundo lugar, mientras que macOS y Otros tienen menor peso. Esta representación permite visualizar rápidamente y de forma clara cómo se reparten las preferencias.

HISTOGRAMA

El histograma es una herramienta fundamental para analizar variables cuantitativas continuas, o discretas con muchos valores distintos. Su principal utilidad es que permite observar cómo se distribuyen los datos en distintos rangos de valores, agrupando las observaciones en intervalos (clases). A diferencia del gráfico de barras, en el histograma las barras están pegadas, porque representan rangos continuos, no categorías independientes.

En el eje horizontal se ubican los intervalos de clase, mientras que en el eje vertical se representan las frecuencias correspondientes a cada intervalo. La altura de cada barra es proporcional a la frecuencia, y el área total del gráfico refleja la totalidad de los datos.

El histograma permite detectar si los datos están concentrados en ciertas zonas, si la

distribución es simétrica o presenta asimetría, y si existen posibles valores atípicos.


Ejemplo: Un docente de la Tecnicatura Universitaria en Programación desea analizar la distribución de edades de sus estudiantes. Para ello, agrupa las edades en intervalos regulares y construye un histograma con frecuencias absolutas. Este gráfico le permite observar si hay rangos etarios predominantes, cómo se comporta la distribución general, y si hay grupos poco representados dentro del curso.

Edades de los alumnos de la TUP TM

21	18	19	20	19	18
20	19	19	19	18	20
19	20	18	21	20	19
20	18	19	19	19	21
22	19	20	18	21	20

Solución:

x_i	f_i	F_i	f_r	F_r
18	6	6	0,200	0,200
19	11	17	0,367	0,567
20	8	25	0,267	0,833
21	4	29	0,133	0,967
22	1	30	0,033	1,000



¿Qué información nos brinda este gráfico?

A partir del histograma, se observa que la mayor concentración de estudiantes se encuentra en los rangos de 18 a 20 años. A partir de los 21, la frecuencia disminuye de forma progresiva, y solo unos pocos casos se ubican en el extremo superior (22 años). El gráfico permite inferir que el grupo está mayoritariamente compuesto por personas jóvenes que probablemente están iniciando su formación universitaria de forma inmediata tras finalizar el secundario.

En algunos casos, utilizar clases de igual amplitud para construir un histograma puede ocultar aspectos importantes de la distribución. Esto ocurre, por ejemplo, cuando los datos están muy concentrados en una región y dispersos en otras: si usamos intervalos iguales, podríamos terminar con barras vacías o con muchas observaciones comprimidas en una sola clase.


Para solucionar este problema, se pueden utilizar intervalos de clases desiguales, es decir, algunos más anchos y otros más estrechos. Como esto afecta la comparación visual entre barras, se calcula una nueva medida: la densidad de frecuencia, que se obtiene dividiendo la frecuencia de cada clase por el ancho del intervalo. Esta densidad se representa en el eje vertical, de modo que el área de cada barra sigue siendo proporcional a la frecuencia de datos dentro de ese intervalo:

$$\text{altura del rectángulo} = \frac{\text{frecuencia relativa de la clase}}{\text{ancho de la clase}} = \frac{f_r}{A}$$

Ejemplo: Durante una auditoría del sistema de seguimiento de bugs en una empresa de desarrollo de software, se registró la cantidad de errores detectados en 48 sesiones de prueba automatizadas. Al analizar los datos, se observó una alta concentración de sesiones con pocos errores, junto a un grupo más reducido de sesiones con cantidades significativamente mayores. Para reflejar con precisión esta distribución, se optó por agrupar los datos en intervalos de clases de distinto ancho, utilizando intervalos más estrechos donde los datos estaban más concentrados y más amplios en los extremos.

A partir de esta agrupación, se calculó la densidad de frecuencia para cada clase, dividiendo la frecuencia absoluta por el ancho del intervalo. Esto permitió construir un histograma de densidad, donde la altura de cada barra representa la densidad, y el área refleja la cantidad de sesiones contenidas en ese rango.

Int.	x_i	f_i	F_i	f_r	F_r	Densidad
[2 – 4)	3	9	9	0,1875	0,1875	0,094
[4 – 6)	5	15	24	0,3125	0,5000	0,156
[6 – 8)	7	5	29	0,1042	0,6042	0,052
[8 – 12)	10	9	38	0,1875	0,7917	0,047
[12 – 20]	16	8	46	0,1667	0,9583	0,021
[20 – 30]	25	2	48	0,0417	1,0000	0,004
		48		1,0000		



¿Qué información nos brinda este gráfico?

El histograma permite identificar claramente que la mayoría de las sesiones de prueba registraron entre 2 y 6 errores, representadas por intervalos más estrechos, pero con densidades altas. A medida que aumenta la cantidad de errores, la densidad disminuye, lo que indica que esos casos fueron menos frecuentes. Gracias al uso de clases desiguales y al ajuste por densidad, se evita que los valores extremos distorsionen la percepción general. Esta representación más fiel de la distribución ayuda a tomar decisiones informadas sobre los puntos críticos del proceso de prueba y asignar recursos con mayor eficiencia.

POLÍGONO DE FRECUENCIAS

El polígono de frecuencias es una representación gráfica que permite visualizar de manera clara la forma de una distribución. Consiste en un gráfico de líneas que conecta los puntos formados por las marcas de clase y sus correspondientes frecuencias. Se puede construir tanto con frecuencias absolutas como relativas.

Este gráfico puede utilizarse como alternativa al histograma o superpuesto sobre él. A diferencia del histograma, el polígono facilita la comparación entre dos o más distribuciones en una misma gráfica, ya que la superposición de líneas es más sencilla que la de barras.

Para construir un polígono de frecuencias:


1. Se calcula la marca de clase de cada intervalo.
2. Se grafica un punto por cada marca de clase en el eje X, con su frecuencia en el eje Y.
3. Se unen los puntos con segmentos de línea.

Ejemplo:


Un equipo de pruebas automatizadas mide los tiempos de ejecución (en segundos) de un algoritmo de análisis sintáctico aplicado a múltiples archivos de código. Los tiempos se agrupan en intervalos, y se construye un polígono de frecuencias para visualizar cómo se distribuyen estos tiempos y detectar posibles desviaciones o irregularidades.

Int.	x_i	f_i	F_i
[0-2)	1	3	3
[2-4)	3	7	10
[4-6)	5	12	22
[6-8)	7	9	31
[8-10)	9	6	37
[10-12)	11	3	40

Polígono de frecuencia absoluta:



Polígono de frecuencia acumulada:



Este gráfico permite observar cómo se acumulan los valores y detectar zonas de crecimiento más rápido o lento

GRÁFICO DE CAJAS

El gráfico de cajas (también conocido como boxplot) es una herramienta poderosa para explorar la distribución de un conjunto de datos y detectar posibles valores atípicos.

Resume la información en cinco valores clave:

- el dato más chico,
- el primer cuartil (Q_1),
- la mediana (Q_2),
- el tercer cuartil (Q_3),
- y dato más grande.

Estos cinco números se representan gráficamente mediante una “caja” que abarca desde Q_1 hasta Q_3 , con una línea que marca la mediana. De cada extremo de la caja salen los llamados “bigotes”, que se extienden hasta los valores más alejados, siempre

que no sean considerados atípicos. Si hay valores que están demasiado lejos del resto (más allá de 1,5 veces el rango intercuartílico), se grafican como puntos individuales y se los considera valores atípicos.

El gráfico de cajas es especialmente útil para observar la dispersión de los datos, comparar varios grupos de datos entre sí, detectar outliers.

Ejemplo:

Un equipo de desarrollo analiza los tiempos de carga en segundos de una aplicación web durante distintas pruebas realizadas a lo largo de varios días. Los tiempos registrados son los siguientes:

0.10; 0.50; 0.90; 1.10; 1.30; 1.50; 1.70; 1.90; 2.10; 2.20; 2.30; 2.40; 2.50; 2.60; 2.70; 2.80; 2.90; 3.10; 3.23; 3.37; 3.50; 3.63; 3.77; 3.90; 4.10; 4.95


Construimos la tabla de frecuencias para datos agrupados, calculamos los estadísticos y organizamos los datos para la construcción del diagrama:

Int.	x_i	f_i	F_i
[0,1 – 0,9)	0,5	2	2
[0,9 – 1,7)	1,3	4	6
[1,7 – 2,5)	2,1	6	12
[2,5 – 3,3)	2,9	7	19
[3,3 – 4,1)	3,7	5	24
[4,1 – 4,9)	4,5	2	26

Datos para construir el gráfico de cajas:

- Mínimo: 0,10
- Q_1 (Primer cuartil): 1,77
- Mediana (Q_2): 2,61
- Q_3 (Tercer cuartil): 3,38
- Máximo: 4,95
- RIC (Rango Intercuartílico): 1,61

- Límite inferior para valores atípicos: – 0,64
- Límite superior para valores atípicos: 5,80



¿Qué información podemos interpretar del gráfico?

El gráfico de cajas permite observar que los tiempos de carga de la aplicación web se encuentran mayormente concentrados entre 1,77 y 3,38 segundos, que corresponden al primer y tercer cuartil. La mediana, ubicada en 2,61 segundos, muestra que la mitad de las cargas se completan en un tiempo inferior a ese valor.

No se identifican valores atípicos, lo cual indica una distribución bastante homogénea de los tiempos, sin ejecuciones anormalmente lentas o rápidas. El valor mínimo registrado es de 0,10 segundos y el máximo de 4,95 segundos, ambos dentro del rango esperable.


Los diagramas de caja son especialmente útiles cuando se desea comparar visualmente varias distribuciones de datos. Al representar múltiples gráficos de caja en

un mismo eje, es posible observar con claridad cómo se comportan diferentes grupos en relación con:

- su tendencia central (mediana),
- la dispersión de los valores (longitud de la caja y de los bigotes),
- la presencia de valores atípicos,
- y las asimetrías en la distribución de los datos.

Esta capacidad de síntesis visual convierte a los boxplots en una herramienta poderosa para el análisis comparativo, tanto en contextos académicos como profesionales.

Ejemplo:



A MODO DE CONCLUSIÓN DE ESTE APUNTE

Representar los datos mediante gráficos no es un paso menor ni meramente ilustrativo, es una herramienta fundamental para explorar, comprender y comunicar información de forma efectiva. Una buena visualización permite descubrir lo que una tabla no muestra, ayuda a detectar errores, resalta patrones relevantes y favorece la toma de decisiones fundamentadas.

Sin embargo, no todos los gráficos sirven para todos los casos. Elegir cuidadosamente el tipo de representación más adecuado requiere considerar el tipo de variable, la cantidad de datos disponibles, el propósito del análisis y el público destinatario. No se trata solo de saber construir gráficos, sino también de desarrollar el criterio para seleccionarlos, interpretarlos críticamente y comunicar con claridad.

En el campo de la programación, donde los datos son cada vez más abundantes y complejos, dominar los métodos gráficos será clave para convertir la información en conocimiento útil. Una representación gráfica bien elegida puede marcar la diferencia.