

UNIDAD N°4

INFERENCIA ESTADÍSTICA

INFERENCIA ESTADÍSTICA: CONCEPTOS FUNDAMENTALES

1. Introducción general

La **inferencia estadística** es el conjunto de métodos que permite extraer conclusiones sobre una población a partir del análisis de una muestra. Esta rama de la estadística es esencial cuando no es posible o conveniente estudiar todos los elementos de una población, ya sea por razones económicas, logísticas o temporales.

En contextos como el análisis de rendimiento de sistemas, el diseño de productos digitales o la toma de decisiones basada en datos (Data-Driven Decisions), trabajar con muestras es la única alternativa viable. Pero, para que estas muestras produzcan conclusiones válidas, es imprescindible comprender cómo se construyen, cómo se analizan y cómo se infieren parámetros poblacionales a partir de ellas.

2. Población, muestra y parámetros

Antes de avanzar con los métodos inferenciales, es fundamental delimitar algunos conceptos básicos:

- **Población:** conjunto completo de elementos que se desea estudiar. Puede ser finita (usuarios de un sistema) o infinita (resultados posibles de un experimento aleatorio continuo).
- **Muestra:** subconjunto de la población que debe ser representativo de ella.
- **Parámetro:** valor numérico (desconocido en general) que describe una característica de la población. Ejemplo: media real de ingresos de todos los usuarios de una app.
- **Estadístico:** valor calculado a partir de los datos de una muestra, usado para estimar un parámetro. Ejemplo: media muestral.

 **Ejemplo aplicado:** queremos saber la tasa real de error de una API. Evaluamos su comportamiento sobre 1000 solicitudes aleatorias (muestra) para estimar su tasa de error total (parámetro).

3. Teoría del muestreo

La calidad de una inferencia depende críticamente de la forma en que se obtuvo la muestra. La **teoría del muestreo** establece las bases para que una muestra sea considerada válida para inferencia.

3.1 Tipos de muestreo probabilístico

Tipo	Descripción	Ejemplo práctico
Simple aleatorio	Cada elemento tiene la misma probabilidad de ser seleccionado	Elegir usuarios al azar para testeo A/B
Estratificado	Se divide la población en estratos homogéneos y se selecciona muestra aleatoria dentro de cada uno	Evaluar por región o sistema operativo
Por conglomerados	Se eligen grupos heterogéneos al azar (conglomerados)	Elegir servidores completos como unidades
Sistemático	Selección regular tras un inicio aleatorio	Evaluar cada 50.º request en un log

3.2 Errores asociados al muestreo

- **Error muestral:** variabilidad inherente entre muestras, incluso si son tomadas correctamente.
- **Error no muestral:** errores provocados por mala recolección, procesamiento o interpretación de los datos.
- **Sesgo:** error sistemático que desvía las estimaciones siempre en la misma dirección (positiva o negativa).

En programación estadística o Data Science, estos errores se reflejan en resultados inestables o modelos sobre ajustados a datos no representativos.

4. Distribuciones muestrales

Cuando trabajamos con una muestra, cualquier estadístico calculado (como la media muestral o la proporción muestral) no es un valor fijo, sino que **varía de una muestra a otra**. Por tanto, podemos considerarlo una **variable aleatoria**, con su propia distribución de probabilidad.

4.1 ¿Qué es una distribución muestral?

La **distribución muestral** de un estadístico es la distribución de todos los posibles valores que ese estadístico puede tomar si repitiéramos infinitamente el proceso de muestreo del mismo tamaño bajo las mismas condiciones.

Si extraemos múltiples muestras del mismo tamaño de una población, la media muestral $\bar{x}$ variará de una muestra a otra, pero tenderá a agruparse alrededor del valor real de la media población μ . Esta propiedad es fundamental para la inferencia estadística. El comportamiento de esos valores forma la **distribución muestral de la media**.

4.2 Propiedades de la distribución muestral de la media

- Si la población es normal con media μ y desviación estándar σ , entonces la distribución muestral de $\bar{x}$ es:

$$\bar{x} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

- Si la población **no** es normal, el **Teorema Central del Límite** establece que:

Si $n \geq 30$, $\bar{x}$ se distribuye aproximadamente como $\mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$

Este resultado es esencial: permite utilizar modelos normales para inferencia aun sin conocer la forma de la población original.

4.3 Ejemplo práctico

Población: tiempos de respuesta de un servidor con media $\mu = 500$ ms y $\sigma = 80$ ms.

Muestra: tomamos muestras de tamaño 25. La media muestral tendrá:

$$\bar{x} \sim \mathcal{N}\left(500, \frac{80^2}{25}\right) = \mathcal{N}(500, 256)$$

Es decir, su desvío estándar será $\sigma_{\bar{x}} = 16$.

5. Estimadores: concepto y propiedades

Un **estimador** es una regla o fórmula que se aplica sobre los datos de una muestra para obtener una aproximación de un parámetro poblacional. El valor numérico resultante se llama **estimación**.

5.1 Ejemplos de estimadores comunes

Parámetro poblacional	Estimador muestral
Media μ	Media muestral $\bar{x}$
Proporción p	Proporción muestral $\hat{p}$
Varianza σ^2	Cuasivarianza muestral s^2

5.2 Propiedades deseables de los estimadores

1. **Insesgadez:** un estimador $\hat{\theta}$ es insesgado si:

$$\mathbb{E}[\hat{\theta}] = \theta$$

2. **Eficiencia:** entre dos estimadores insesgados, es más eficiente el que tiene **menor varianza**.
3. **Consistencia:** un estimador es consistente si, al aumentar el tamaño muestral, converge al valor verdadero del parámetro:

$$\hat{\theta}_n \xrightarrow{p} \theta$$

5.3 Ejemplo conceptual

Objetivo: Estimar la proporción de errores de login en un sistema.

- Tomamos una muestra de 200 intentos y observamos 30 fallos.
- La proporción muestral es $\hat{p} = \frac{30}{200} = 0.15$
- Esto es una **estimación puntual insesgada** del verdadero p , suponiendo muestreo aleatorio.

6. Estimación puntual e intervalos de confianza

6.1 Estimación puntual

Es la técnica más directa: se calcula un único valor para aproximar el parámetro poblacional.

Ejemplo: $\bar{x} = 45.2$ minutos (tiempo promedio de sesión)

Limita: no indica **cuán confiables** somos respecto a la cercanía al valor real.

6.2 Estimación por intervalo

Aquí se construye un **rango** de valores que, con cierto nivel de confianza, contiene al parámetro buscado.

Ejemplo: $\bar{x} \in [43.1, 47.3]$ con un nivel de confianza del 95%

Esto significa: si repitiéramos el experimento muchas veces, el 95% de los intervalos así contruidos contendrían el verdadero valor de μ .

6.3 Factores clave en la construcción del intervalo

- Tamaño de la muestra n
- Nivel de confianza deseado (generalmente 90%, 95%, 99%)
- Desvío estándar de la población (si se conoce) o de la muestra

7. Intervalos de confianza (IC)

La **estimación por intervalo** permite establecer una franja de valores donde es altamente probable que se encuentre el parámetro poblacional que estamos tratando de estimar. Este rango está determinado por:

- El **nivel de confianza** deseado (generalmente 90%, 95% o 99%)
- La **variabilidad** de los datos (desvío estándar)
- El **tamaño de la muestra** n

Un **intervalo de confianza al 95%** significa: si repitiéramos el proceso de muestreo muchas veces, el 95% de los intervalos construidos de esta forma contendrían al verdadero parámetro poblacional.

7.1 IC para la media con desviación estándar conocida

Se usa la **distribución normal estándar** cuando la desviación poblacional σ es conocida.

Fórmula:

$$IC = \left[\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right]$$

- $\bar{x}$: media muestral
- σ : desvío estándar poblacional
- $z_{\alpha/2}$: valor z para el nivel de confianza (por ejemplo, 1.96 para 95%)
- n : tamaño de la muestra

7.2 Ejemplo con σ conocida

Una muestra de 25 viviendas tiene una media de superficie de $102,5 \text{ m}^2$ y se sabe que $\sigma = 7 \text{ m}^2$. Queremos el intervalo al 95%.

$$IC = 102.5 \pm 1.96 \cdot \frac{7}{\sqrt{25}} = 102.5 \pm 2.744$$
$$IC = [99.756, 105.244]$$

7.3 IC para la media con σ desconocida

Cuando no conocemos el desvío poblacional, usamos el **desvío muestral** s y la **distribución t de Student**, con $n-1$ grados de libertad.

Fórmula:

$$IC = \left[\bar{x} - t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}} \right]$$

7.4 Ejemplo con σ desconocida

En una muestra de 20 usuarios, la media de tiempo de carga es $\bar{x} = 3.5$ seg y el desvío estándar muestral es $s = 0.8$ seg. Nivel de confianza: 95%.

- $t_{0.025, 19} \approx 2.093$

$$IC = 3.5 \pm 2.093 \cdot \frac{0.8}{\sqrt{20}} = 3.5 \pm 0.374$$
$$IC = [3.126, 3.874]$$

7.5 IC para una proporción poblacional

Si queremos estimar una proporción p (como la tasa de clics en una app), usamos:

$$IC = \left[\hat{p} - z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

⚠ Este modelo se aplica solo si $np \geq 5$ y $n(1-p) \geq 5$

7.6 Ejemplo de proporción

En una encuesta a 150 usuarios, 120 están satisfechos. Entonces:

$$\hat{p} = \frac{120}{150} = 0.8$$

$$IC = 0.8 \pm 1.96 \cdot \sqrt{\frac{0.8 \cdot 0.2}{150}} = 0.8 \pm 0.045$$

$$IC = [0.755, 0.845]$$

7.7 IC para la varianza poblacional

Si la variable tiene distribución normal, usamos la distribución **chi-cuadrado** con $n - 1$ grados de libertad.

Fórmula:

$$IC = \left[\frac{(n-1)s^2}{\chi^2_{1-\alpha/2}}, \frac{(n-1)s^2}{\chi^2_{\alpha/2}} \right]$$

- s^2 : cuasivarianza muestral
 - χ^2 : valor crítico de la distribución chi-cuadrado
-

7.8 Observaciones clave

- A mayor tamaño de muestra n , **más estrecho** será el intervalo.
- A mayor nivel de confianza, **más amplio** será el intervalo.
- El uso correcto del modelo (normal o t) depende de conocer o no σ

8. Visualización gráfica de los intervalos de confianza

Las representaciones visuales ayudan a comprender mejor el sentido de los intervalos y cómo el nivel de confianza afecta su amplitud.


8.1 Campana de Gauss e IC al 95%

En una distribución normal estándar $\mathcal{N}(0, 1)$, el 95% del área se encuentra entre $z = -1.96$ y $z = +1.96$. Esto significa que:

$$P(-1.96 \leq Z \leq 1.96) = 0.95$$

Esto se traduce, para cualquier media muestral $\bar{x}$, en un intervalo simétrico centrado en $\bar{x}$ con un margen de error:

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$



8.2 Efecto del tamaño de muestra sobre el intervalo

Con muestras más grandes, el error estándar $\sigma/\sqrt{n}$ disminuye y por lo tanto **el intervalo es más estrecho**, brindando estimaciones más precisas.

Tamaño muestral n	Margen de error
25	mayor
100	menor
1000	aún menor

8.3 Comparación visual: distintos niveles de confianza

Nivel de confianza	z-valor	Intervalo
90%	1.645	más estrecho
95%	1.960	estándar
99%	2.576	más amplio

Esto muestra que hay un **balance entre precisión y certeza**: a mayor certeza, más amplio el rango.

9. Ejercicios desarrollados

Ejercicio 1: IC para la media con σ conocida

Contexto: En una muestra de 64 servidores, el tiempo de respuesta medio es de 2.4 s y se conoce que $\sigma = 0.5$ s. Obtener IC al 95%.

Solución:

$$z_{0.025} = 1.96, \quad n = 64, \quad \bar{x} = 2.4$$

$$IC = \bar{x} \pm z \cdot \frac{\sigma}{\sqrt{n}} = 2.4 \pm 1.96 \cdot \frac{0.5}{8} = 2.4 \pm 0.1225$$

$$IC = [2.2775, 2.5225] \text{ segundos}$$

Ejercicio 2: IC para proporción

Situación: Se realiza una prueba en 400 sesiones de usuarios, y 340 completan la acción deseada. Calcular el IC al 95% para la proporción de éxito.

Solución:

$$\hat{p} = \frac{340}{400} = 0.85, \quad z = 1.96$$

$$IC = 0.85 \pm 1.96 \cdot \sqrt{\frac{0.85 \cdot 0.15}{400}} = 0.85 \pm 0.0327$$

$$IC = [0.8173, 0.8827]$$

Interpretación: con 95% de confianza, entre el 81.7% y el 88.3% de los usuarios completan la acción en toda la población.

Ejercicio 3: IC para la media con σ desconocida

Caso: Se mide el tiempo de carga en 15 sitios. La media es de 1.8 s, con desviación estándar muestral $s = 0.6$. IC al 95%.

Solución:

- $n = 15, t_{0.025, 14} \approx 2.145$

$$IC = 1.8 \pm 2.145 \cdot \frac{0.6}{\sqrt{15}} = 1.8 \pm 0.332$$

$$IC = [1.468, 2.132] \text{ s}$$

10. Glosario de términos clave

Término	Definición académica
Población	Conjunto total de individuos, casos u observaciones de interés para un estudio
Muestra	Subconjunto representativo de la población, seleccionado para realizar inferencias
Parámetro	Medida numérica que resume una característica de la población (ej. μ , p , σ^2)
Estadístico	Medida calculada a partir de una muestra que se utiliza para estimar un parámetro
Estimador	Regla o fórmula que se aplica a los datos muestrales para aproximar un parámetro
Estimación puntual	Valor único calculado como aproximación de un parámetro poblacional
Intervalo de confianza (IC)	Rango de valores dentro del cual, con cierta confianza, se espera encontrar el valor del parámetro
Nivel de confianza	Probabilidad (como 0.95) de que un intervalo contenga el valor real del parámetro
Error estándar (SE)	Medida de la variabilidad del estadístico (ej. $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$)
Z-score	Valor crítico de la distribución normal estándar usado para construir IC cuando σ es conocida
T de Student	Distribución usada en lugar de la normal cuando σ es desconocida y n es pequeño
Distribución muestral	Distribución de probabilidades del valor de un estadístico obtenido a partir de múltiples muestras
Teorema Central del Límite (TCL)	Establece que, para muestras grandes, la media muestral se distribuye normalmente, incluso si la población original no lo es
Sesgo	Error sistemático que conduce a estimaciones sistemáticamente alejadas del parámetro verdadero
Error muestral	Variación aleatoria inevitable entre diferentes muestras tomadas de la misma población

11. Consideraciones finales para la práctica profesional

- En programación, ingeniería de datos y desarrollo web, la inferencia estadística es fundamental para:
 - Evaluar la **usabilidad de sistemas** con encuestas parciales
 - Detectar **anomalías** o caídas de rendimiento en servidores
 - Validar hipótesis** con A/B Testing
 - Estimar **tasas de error o éxito** con métricas muestrales
 - Optimizar recursos y tomar decisiones basadas en datos con rigor

- Comprender los fundamentos de la inferencia permite **evitar errores de interpretación**, como asumir que una diferencia observada en una muestra es concluyente sin evaluar su significancia estadística.

La estadística inferencial no reemplaza la observación directa de toda la población: la complementa y la potencia, ofreciendo herramientas para tomar decisiones fundamentadas en evidencia.

12. Recursos complementarios sugeridos

-  *Introducción a la Inferencia Estadística* — Sheldon Ross
-  *Applied Statistics and Probability for Engineers* — Montgomery & Runger
-  Simuladores como PhET Simulations para distribución muestral
-  Calculadoras interactivas de IC: stattrek.com